

第 01 周 视频思考题

(week1 学习内容: 机器学习基础、线性回归、逻辑斯蒂回归)

01. 什么是显式编程、隐式编程?

答: 显式编程是代码明确地定义和控制每一个步骤和操作, 如 C 语言经典的冒泡排序算法。

隐式编程是不能通过简单的代码完成解决事情, 而是通过高层次的抽象和自动化方法如多个流程、规则、模式、逻辑等的嵌套结合去实现的, 如手写数字识别、人脸识别等这些任务里面需要用到大量的隐式编程。

02. 在完成人脸识别的任务过程中, T、P、E 分别可以是什么?

答: 人脸识别的任务过程是一个分类型匹配任务, 所以 T 是分类识别任务、P 可以是识别的错误率、E 是训练用的人脸图像数据集。

03. 在完成天气温度预测的任务过程中, T、P、E 分别可以是什么?

答:

T 是完成某某局部地区某某天的气温预测, 所以这个任务是建立一个关联函数

$$f_1(\text{气压、湿度、风向、云层等气象数据}) = \text{温度}$$

同时考虑地理因素是一个非常重要的影响指标, 众所周知, 我国有一些非常重要的地理分界线如秦岭淮河线, 来自西伯利亚的冷空气大概率不会穿越秦岭山脉, 从而可能导致关联关系 f_1 函数在秦岭以南的地方不适用, 或者因为某些山区特殊的地理构造而不适用, 所以考虑加上地理因素构建 f_2 函数

$$f_2(\text{气压、湿度、风向、云层等气象数据、地理地貌影响}) = \text{温度}$$

P 可以是预测气温与当日实际测量气温的绝对误差。

E 是过往的气象图数据数据集, 可能包括地理坐标-大气压/风速/风向/湿度等气象领域指标分布图, 如图 1 所示。



图 1 地理坐标-气象数据分布图示例

04. 结合视频《004 机器学习形式化定义及相关概念》内容认识 MNIST 数据集和 IRIS(鸢尾花)数据集，并回答各自数据集中样本特征、特征向量、特征维度、类别与类别标签分别是什么？

答：


	样本特征	特征向量	特征维度	类别	类别标签
MNIST 数据集	● 每个样本是一张 28×28 像素的灰度图像，代表 0 到 9 的手写数字 ● 图像中每个像素的灰度值范围为 0-255（0 表示纯黑，255 表示纯白）	图 片 像 素 28*28=784 个像素点构成的特征向量，每个像素点的向量包含了图像中该像素点像素的灰度值信息	每张图片的像素点个数 784 就是特征维度	所属“0-9”具体哪一个数字类别，一共 10 个类别	单个数字（0-9），这个数据集中恰好使用数字标记“数字类别”
IRIS 数据集	● 150 个样本，均匀分为 Setosa 、Versicolour 、Virginica 三类，每类 50 个样本 ● 每个样本包含 4 个特征	每个样本形成一个 4 维的特征向量（花萼长度，花萼宽度，花瓣长度，花瓣宽度）	特征维度为 4（花萼长度，花萼宽度，花瓣长度，花瓣宽度）	三种鸢尾花品种 Iris Setosa（山鸢尾） Iris Versicolour（杂色鸢尾） Iris Virginica（维吉尼亚鸢尾）	用 整 数 表 示 (Setosa=0, Versicolour=1, Virginica=2)

05. 结合视频《003 机器学习从数据中获取映射关系》、《 004 机器学习形式化定义及相关概念》内容回答，如何借助 MNIST 数据集，利用机器学习实现图片中手写数字的识别？

答：为了完成手写数字识别分类（T），我将首先将 MNIST 数据集（E）划分为训练集和测试集。对训练集训练出识别模型函数后，去实际测试测试集来验证模型识别准确率（P）是否很高，如果使用模型对测试集的识别准确率不高，我可能会利用 8 折交叉验证的方法去做一个更为广泛充分的学习迭代，捕捉尽可能全部样本特征，来提高模

型识别准确率（P），直到达到符合规定的识别准确度为止。

06. 下面左中右三图中，哪个模型最好？另外两个又出现了什么问题？



答：B 模型最好。A 模型存在欠拟合（选用了非常简单的线性模型来拟合非线性问题）、C 模型存在过拟合（可能选用了复杂度更高的函数模型来拟合，如选用了一元三次函数甚至一元五次函数来拟合二次函数问题）。

07. 二分类模型模型预测结果如下：

- 对于 150 个患病的患者，模型将其中 130 个患者正确地分类为患有疾病，但错误地将 20 个患者判断为健康。
- 对于 50 个健康的患者，模型将其中 45 个患者正确地分类为健康，但错误地将 5 个患者判断为患病。

请根据上述内容完成：

7.1 结合实际分析，当前正例是什么？

答：根据题目场景得知为医学健康场景。在医疗诊断场景中，患病的人应该作为正类(Positive)，健康的人作为负类(Negative)。这是行业惯例，也是符合医学诊断实际需求的定义方式，这是因为：

- 我们的主要目标是识别出患病的人（识别出潜在的恶性病例，因为这些人是需要关注和提前治疗的）
- 漏诊（假阴性）通常比误诊（假阳性）更严重，如 IVD 行业对于 HIV、梅毒的假阳性要求要大于。

7.2 画出混淆矩阵

	Predicted Positive	Predicted Negative
Actual Positive (患病)	TP = 130	FN = 20

Actual Negative (健康)	FP = 5	TN = 45
----------------------	--------	---------

7.3 分别计算查准率、查全率和正确率

$$\text{查准率(Precision)} = \frac{TP}{TP + FP} = \frac{130}{135} * 100\% \approx 96.3\%$$

$$\text{查全率(Recall)} = \frac{TP}{TP + FN} = \frac{130}{150} * 100\% \approx 86.6\%$$

$$\text{正确率(Accuracy)} = \frac{TP + TN}{TP + TN + FN + FP} = \frac{175}{200} * 100\% \approx 87.5\%$$

08. 假设有一个儿童身高统计数据，其中包含 10000 个样本。每个样本都包含年龄、性别、父母身高、每周户外运动时长和身高信息。

1. 请使用线性回归来训练得到一个可以预测身高的模型，该模型结构是怎样的？

首先我通过题意得知数据集里面包含影响因素（年龄、性别、父母身高、每周户外运动时长）与结果（身高）两种类型数据，然后需要使用线性回归模型，所以可以得到一个 4 个自变量的函数表达形式

$$f = \sum_{j=1}^4 W_j x_j + b$$

- $x_1 \sim x_4$ 分别是年龄、性别、父母身高、每周户外运动时长
- f 为身高数据

2. 使用小批量梯度下降的方式对模型进行训练，请实现该过程对应伪代码。

```
# 初始化
parameters = initialize_parameters()
data = shuffle(data) # 每个 epoch 开始前打乱数据

for epoch in range(num_epochs):
    for i in range(0, len(data), batch_size):
        batch = data[i:i+batch_size]
        gradient = compute_gradient(batch, parameters) # 梯度计算
        parameters -= learning_rate * gradient
```

9. 尝试画出 y^i 分别为 0,1 时代价函数的图像(设 $m=1$)。

$y^i \Rightarrow 0, 1$ $f(x^i)$: 正例概率, $1 - f(x^i)$: 负例概率


$$J_{(w,b)} = -y^i \ln f(x^i) - (1 - y^i) \ln [1 - f(x^i)]$$

答：当 y^i 取 1 的时候，

$$j(w, b) = \ln(1 + e^{-(wx^i + b)})$$

画图如下（给 x 赋值, $x=1$ 时）

$$\tilde{j}(w, b) = \log(1 + e^{-1wx + b}), \text{ with } x = 1.0$$



当 y^i 取 0 的时候，

$$j(w, b) = \ln(1 + e^{wx + b})$$

画图如下（给 x 赋值, $x=1$ 时）

$$\tilde{j}(w, b) = \ln(1 + e^{wx + b}), \text{ with } x = 1.0$$

