


01. 手画出 Transformer 模型架构，并将数据在模型架构中的流动进行描述



02. 如何理解深度学习中注意力机制？

答：“用当前任务的需求（Q），去资料库里按重要性加权（QK 计算得到）取信息（V）。”

注意力的比喻：在写总结时，能“按问题”去翻书、划重点；每次问题不同，划重点的位置也不同。

02. 如何理解注意力机制中的 QKV？

答：最常用的比喻：**图书检索系统**

- **Q (Query, 查询)：**你现在想找什么？（问题/意图）
- **K (Key, 索引)：**每本书的“关键词标签”（用来匹配查询）
- **V (Value, 内容)：**书本真正的内容（最终要取走的信息）

流程：用 Q 去和所有 K 算相似度 → 得到权重 → 用权重对 V 做加权求和 → 得到“这次真正需要的摘要”。

04. QKV 从哪里得到？如何得到？


答：分两种情况，自注意力和交叉注意力。

1) 对于自注意力。Q,K,V 是输入的词向量 X 经过全连接层，分别乘以三个参数得到的。

$$Q = XW_Q, \quad K = XW_K, \quad V = XW_V$$

2) 对于交叉注意力。Q 来自于 Decoder 上一次的输出，K 和 V 来自于左侧的 Encoder。

05. Transformer 的注意力计算方式中，为什么要进行缩放？



答：因为 softmax 计算公式里面引入了指数函数 e^x ，虽然对于输入的 x 轻微的变化在对应的 y 上有了很大的差异。假如不除以根号 d_k 这个缩放动作，很容易出现注意力权重会变得很极端。下面举了 d_k 两个不同的例子来说明，当 d_k 维度上去之后，如果不使用“缩放”，造成的权重分配变得极端的例子（只考虑 Q,K 计算，不考虑 V）。

1) 先做 $d_k = 4$ 的例子

取:

- $q = [1, 1, 1, 1]$
- $k_1 = [1, 1, 1, 1]$
- $k_2 = [1, 1, 1, 0]$
- $k_3 = [1, 0, 0, 0]$

- $s_1 = q \cdot k_1 = 1 \cdot 1 + 1 \cdot 1 + 1 \cdot 1 + 1 \cdot 1 = 4$
- $s_2 = q \cdot k_2 = 1 + 1 + 1 + 0 = 3$
- $s_3 = q \cdot k_3 = 1 + 0 + 0 + 0 = 1$

所以 $s = [4, 3, 1]$

不缩放用softmax算概率

缩放用softmax算概率

算 softmax (用「减最大值」避免大数):

- 减去最大值 4: $[0, -1, -3]$
- 指数: $\exp(0) = 1$, $\exp(-1) = 0.3679$, $\exp(-3) = 0.0498$
- 和: $1 + 0.3679 + 0.0498 = 1.4177$

概率:

- $\alpha_1 = 1/1.4177 = 0.705$
- $\alpha_2 = 0.3679/1.4177 = 0.259$
- $\alpha_3 = 0.0498/1.4177 = 0.035$

$$\tilde{s} = \frac{s}{2} = [2, 1.5, 0.5]$$

再 softmax:

- 减最大值 2: $[0, -0.5, -1.5]$
- 指数: $\exp(0) = 1$, $\exp(-0.5) = 0.6065$, $\exp(-1.5) = 0.2231$
- 和: $1 + 0.6065 + 0.2231 = 1.8296$

概率:

- $\hat{\alpha}_1 = 1/1.8296 = 0.546$
- $\hat{\alpha}_2 = 0.6065/1.8296 = 0.331$
- $\hat{\alpha}_3 = 0.2231/1.8296 = 0.122$

$d_k=64$

$$\text{构造 } Q, K \begin{cases} q = [1, 1, 1, 1, \dots, 1] & \# \text{长度64, 全为1} \\ k_1 = [1, 1, 1, 1, \dots, 1] & \# \text{长度64, 全为1} \\ k_2 = [1, 1, 1, 1, \dots, 0, 0, \dots, 0] & \# \text{长度64, 前48个维度为1, 后16个维度为0} \\ k_3 = [1, 1, 1, 1, \dots, 0, 0, \dots, 0] & \# \text{长度64, 前16个维度为1, 后48个维度为0} \end{cases}$$

- $s_1 = 64$
- $s_2 = 48$
- $s_3 = 16$

$s = [64, 48, 16]$

不缩放用softmax算概率

缩放用softmax算概率

softmax (减最大值 64):

- $[0, -16, -48]$
- $\exp(-16) \approx 1.125 \times 10^{-7}$
- $\exp(-48) \approx 1.78 \times 10^{-21}$

所以概率几乎是:

- $\alpha_1 \approx 0.999999875$
- $\alpha_2 \approx 1.125 \times 10^{-7}$
- $\alpha_3 \approx 1.78 \times 10^{-21}$

$$\tilde{s} = \frac{1}{8}[64, 48, 16] = [8, 6, 2]$$

softmax (减最大值 8):

- $[0, -2, -6]$
- 指数: 1 , $e^{-2} = 0.1353$, $e^{-6} = 0.00248$
- 和: $1 + 0.1353 + 0.00248 = 1.13778$

概率:

- $\hat{\alpha}_1 = 1/1.13778 = 0.879$
- $\hat{\alpha}_2 = 0.1353/1.13778 = 0.119$
- $\hat{\alpha}_3 = 0.00248/1.13778 = 0.00218$

06. 多头注意力的多头是怎样的？如何解释其意义？

答：论文里面是 512 长度分成 8 个头（8 组 Q,K,V），每个头都是 64 长度，最后计算完后会 **Contact** 在一起。如果用语言翻译例子来理解多头作用，就是像一个翻译小组团队同时从不同角度读同一句话：

- 头 1 关注主谓宾关系
- 头 2 关注指代（他/她/它）
- 头 3 关注长距离依赖（开头和结尾的呼应）
- 头 4 关注局部短语搭配
- 头 n....

多头让模型能并行学多种关系子空间。

07.掩码注意力的“掩码”是如何实现的？

输入固定 token 长度，未掩码部分正常缩放公式计算（S），掩码部分(M)用-inf 填充， $\text{softmax}(S+M)$ 后，负无穷得到一个很小的概率数字可以忽略。

08. nn.Embedding 的作用是什么？

将输入 token(离散符号 (id))变成连续向量，方便神经网络计算与泛化

09. Embedding 得到的词向量，具有语义么？

随机初始化时没有语义，训练后有一定的语义，比如“相似语义”、“相似用法”的词往往会在向量空间更接近，比如“男人”和“胡子”、“夫妻”和“夫妇”这些对词向量会在向量空间更加接近。

10. 如何理解 Transformer 中的位置编码？


给一个句子里面词向量带上位置编码，是因为词汇顺序在语言里承载了语义和语法角色（主语/宾语、时间先后、修饰关系等）。没有位置，很多任务在信息论上就不可分辨。比如“狗咬我”、“我咬狗”这两句话在没有位置编码的 LLM 理解起来非常可能表达是一个意思。

- 没有位置编码：能学到一个词像不像另一个词（在一个词集合中进行学习）
- 有了位置编码：加入了位置特征，能学到句子的语法、依赖、邻近关系、长距离依赖等。

11. 位置编码计算公式中 i 的取值范围是？

$$i = 0, 1, 2, \dots, \left(\frac{d_{model}}{2} - 1 \right)$$

12. BatchNorm 和 LayerNorm 的区别是什么？分别适用什么场景？



总结图示表				
方法	归一化对象 (Normalization Target)	依赖的数据维度 (Dimensions)	谁变了?	适用场景
BN	数据 (Activations)	Batch (N) + Spatial (H, W)	不同样本相互影响	CV (CNN), 大Batch
LN	数据 (Activations)	Feature (C) + Spatial (H, W)	单个样本自给自足	NLP (RNN, Transformer), 小Batch
WN	权重 (Weights)	Weights (W) 本身	权重参数被重整	GAN, RL, LSTM

13. Transformer 中的 FeedForward 的存在意义是什么？

全连接做非线性加工与特征变换，提升表达能力

14. 词表中为什么要存在 word2idx 和 idx2word 两种形式？

做一个映射关系表，让模型读 id 数字更快，人类只会读懂“查字典后的”文本。类似以前情报战的摩斯密码本。

- word2idx: 把文本 token $\rightarrow$ 整数 id (用于训练/推理输入)
- idx2word: 把模型输出 id $\rightarrow$ token (用于解码、展示、生成文本)

Morse code

	American	International		American	International		American	International
A	·-·-	·-·-	M	·-·-	·-·-	1	·-·-·-	·-·-·-
Ā		·-·-·-	N	·-·-	·-·-	2	·-·-·-·-	·-·-·-·-
Ă		·-·-·-·-	Ń	·-·-	·-·-·-	3	·-·-·-·-·-	·-·-·-·-·-
Ą		·-·-·-·-·-	Ō	·-·-	·-·-·-	4	·-·-·-·-·-·-	·-·-·-·-·-·-
B	·-·-·-	·-·-·-	Ŏ	·-·-	·-·-·-	5	·-·-·-·-·-·-	·-·-·-·-·-·-
C	·-·-	·-·-·-	P	·-·-·-	·-·-·-	6	·-·-·-·-·-·-	·-·-·-·-·-·-
CH	·-·-	·-·-·-	Q	·-·-·-	·-·-·-	7	·-·-·-·-·-·-	·-·-·-·-·-·-
D	·-·-	·-·-·-	R	·-·-	·-·-	8	·-·-·-·-·-·-	·-·-·-·-·-·-
E	·-	·	S	·-·-	·-·-	9	·-·-·-·-·-·-	·-·-·-·-·-·-
Ė		·-·-·-	T	·-·-	·-·-	0	·-·-·-·-·-·-	·-·-·-·-·-·-
F	·-·-·-	·-·-·-	U	·-·-	·-·-	00	·-·-·-·-·-·-	·-·-·-·-·-·-
G	·-·-·-	·-·-·-	V	·-·-·-	·-·-·-			
H	·-·-·-	·-·-·-	W	·-·-·-	·-·-·-			
I	·-	·-	X	·-·-·-	·-·-·-			
J	·-·-·-	·-·-·-	Y	·-·-·-	·-·-·-			
K	·-·-·-	·-·-·-	Z	·-·-·-	·-·-·-			
L	·-·-·-	·-·-·-						

GSDN 程序员爱星儿

15. Transformer 中的哪些设计是用来规避训练过程中容易出现的梯度问题？

- Residual Connection（残差）：让梯度有“高速通道”绕过深层非线性，缓解梯度消失。
- LayerNorm（以及常见的 Pre-LN 结构）：稳定各层输入分布，训练更稳、更深也不容易炸。
- Scaled Dot-Product Attention（ d_k 缩放）：防止 softmax 饱和导致梯度变差
- 学习率 warmup + 衰减策略（经典 Transformer schedule）：刚开始用小学习率“热身”，避免一上来更新太猛梯度发散。
- Adam/AdamW + 合理初始化：自适应优化器与初始化共同降低训练不稳定风险。
- Dropout / Label smoothing（常见训练技巧）：主要是正则，但也会让训练过程更“平滑”。
- Gradient clipping（很多训练脚本会配）：直接兜底防梯度爆炸。