

下面从模型输出开始，一步一步把「多分类损失」完整走一遍，清楚softmax + 交叉熵为什么是多分类的标准配置，结合具体数值，展示“某个类别是正例时，损失是怎么来的”。

一、从网络输出开始：Logits（未归一化得分）

假设是一个 3 类分类问题：

类别：[猫，狗，鸟]

神经网络最后一层（线性层）神经元数量与类别数相等，此时每个神经元都可以得到任意大小的数值，没有经过激活函数，所以记为 $\mathbf{z}$ ：

$$\mathbf{z} = [z_1, z_2, z_3] = [2.0, 1.0, 0.1]$$

关键点：

- $\mathbf{z}$ 可以是任意实数
- 只是“模型对每个类别的临时打分”，不能直接当概率

二、Softmax：把 $\mathbf{z}$ 变成概率分布

1 Softmax 定义

$$\text{softmax}(z_i) = \frac{e^{z_i}}{\sum_{j=1}^C e^{z_j}}$$

2 带入具体数值

先算指数：

$$e^{2.0} \approx 7.39$$

$$e^{1.0} \approx 2.72$$

$$e^{0.1} \approx 1.11$$

总和：

$$\sum e^z = 7.39 + 2.72 + 1.11 = 11.22$$

得到概率：

$$\mathbf{p} = [0.659, 0.242, 0.099]$$

解释：

类别	模型输出	softmax 概率
猫	2.0	0.659
狗	1.0	0.242
鸟	0.1	0.099

- ✔ 概率和 = 1
- ✔ 最大输出神经元 → 最大概率

三、真实标签：One-Hot 编码

在这里，每个类别标签，会相应转换成 One-Hot 编码。

假设真实类别是：狗

则 One-Hot 标签为：

$$\mathbf{y} = [0, 1, 0]$$

类别猫 One-Hot 标签：

$$\mathbf{y} = [1, 0, 0]$$

类别鸟 One-Hot 标签：

$$\mathbf{y} = [0, 0, 1]$$

这一步非常重要：

- 只有“正例类别”是 1
- 其他类别是 0
- 多分类中：每个样本只有一个正例

四、交叉熵损失：只关心了“正例概率”

1 多分类交叉熵公式

$$\mathcal{L} = - \sum_{i=1}^C y_i \log(p_i)$$

由于 one-hot 的作用，使得类别标签这里只有正例位置为“1”，所以得到：

$$\Rightarrow \mathcal{L} = - \log(p_{\text{true}})$$

也就是说，不管类别数量为多少，这里只有正例位置的类别概率会拿来进行损失的最终运算，其他位置上的类别概率，损失函数里并不会用到。

👉 只看真实类别对应的 softmax 概率

2 代入本例（狗是正例）

$$p_{\text{dog}} = 0.242$$

$$\mathcal{L} = - \log(0.242) \approx 1.42$$

五、需要注意：预测对,也有损失！！

根据公式可以得到：

正例概率	损失
0.99	0.010
0.90	0.105
0.50	0.693
0.10	2.303
0.01	4.605

所以不管正例概率是大，还是小，只要不是1，就都会得到损失。

🔥 结论：

交叉熵就是在惩罚：你对正例“不够自信”

六、下面从“正例”的角度再看一遍流程

对于一个样本，某个类别是正例时：

1 网络输出一个实数作为临时分数

2 softmax 得到概率分布

3 只取正例对应的概率 p_{true}

4 损失 = $-\log(p_{\text{true}})$

所以请注意：

“交叉熵会同时惩罚所有类别” ❌

这是通常容易产生的错误理解。

✅ 正确理解：

前向计算中，只直接惩罚正例；

反向传播中，通过 softmax 的耦合性，使得所有类别都收到了梯度

这里需要结合计算好好理解。

七、再看看对比例子(类别标签依旧为 $[0, 1, 0]$)

情况 A：预测几乎正确

$$\mathbf{p} = [0.05, \mathbf{0.92}, 0.03] \Rightarrow \mathcal{L} = -\log(0.92) \approx 0.083$$

情况 B：预测完全错

$$\mathbf{p} = [0.90, \mathbf{0.05}, 0.05] \Rightarrow \mathcal{L} = -\log(0.05) \approx 3.00$$

现在，你应该对于使用交叉熵损失函数如何得到多分类问题的损失比较清楚了。

八、总结

Softmax 负责“得到概率”，

One-Hot 得到方便计算损失类别编码，

交叉熵负责“惩罚正例的不自信”，

最终形成稳定有效的多分类学习信号。